Wahrscheinlichkeitstheorie und Statistik (Stochastik)

Dr. rer. nat. Johannes Riesterer

Diskrete Wahrscheinlichkeitsverteilung

Beispiel: Hash Kollision

Beim Hashing werden zufällig k Daten auf n Speicherplätze verteilt. Bezeichnen wir mit $A_{k,n}$ die Möglichkeiten der Mehrfachbelegungen von Feldern, so ist das komplementäre Ereignis $A_{k,n}^c = Var_k^n(\Omega, o.W.)$, wobei Ω die Menge der verfügbaren Speicherplätze darstellt.

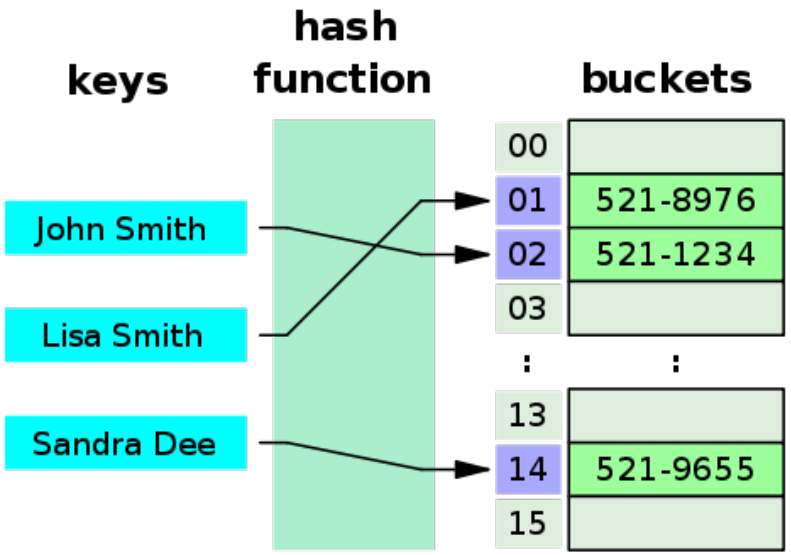

Figure: Quelle: Wikipedia

Diskrete Wahrscheinlichkeitsverteilung

Beispiel: Hash Kollision

$$P(A^c_{k,n}) = \frac{\#Var^n_k(\Omega, o.W.)}{\#Var^n_k(\Omega, m.W.)} =$$

$$\frac{n_k}{n^k} = \frac{n \cdot (n-1) \cdots (n-(k-1))}{n^k} = \prod_{i=0}^{k-1}(1 - \frac{i}{n})$$

$$= \exp(\sum_{i=0}^{k-1} \ln(1 - \frac{i}{n})) \leq \exp(\sum_{i=0}^{k-1}(-\frac{i}{n}))$$

$$(ln(1-x) \leq -x \text{ für } x < 1)$$

$$= \exp(-\frac{(k-1)k}{2n})$$

Diskrete Wahrscheinlichkeitsverteilung

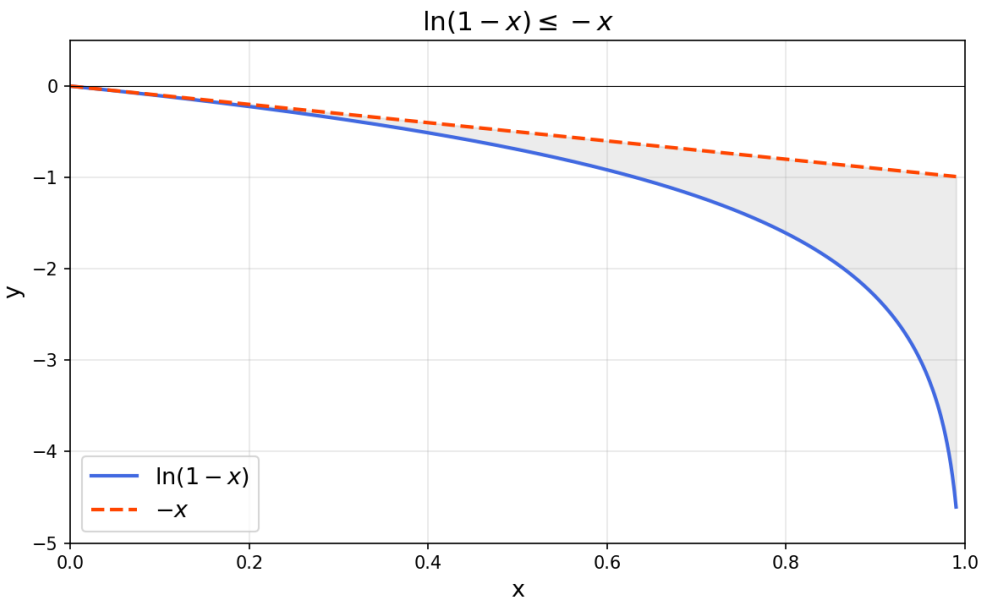

Beispiel: Hash Kollision (Geburtstags-Paradoxon)

Für $n = 365$ und $k = 23$ ist damit $P(A_{k,n}) > \frac{1}{2}$. Die Wahrscheinlichkeit, dass bei einer Gruppe von mehr als 23 Leuten zwei Leute am gleichen Tag Geburtstag haben, ist also größer als $\frac{1}{2}$.

Diskrete Wahrscheinlichkeitsverteilung

Satz der totalen Wahrscheinlichkeit

Für eine Zerlegung $\Omega = \bigcup_{j=1}^{n} B_j$, mit $B_i \cap B_k = \emptyset$ für $i \neq k$

$$P(A) = \sum_{j=1}^{n} P(A \mid B_j) \cdot P(B_j)$$

Beweis

Da $A = A \cap \Omega = A \cap \bigcup_{j=1}^{n} B_j = \bigcup_{j=1}^{n} (A \cap B_j)$ eine disjunkte Zerlegung ist, folgt:

$$P(A) = \sum_{j=1}^{n} P(A \cap B_j) = \sum_{j=1}^{n} P(A \mid B_j) \cdot P(B_j)$$

Satz von Bayes

Für $A, B \in \mathcal{A}$ mit $P(B) > 0$ gilt

$$P(A \mid B) = \frac{P(B \mid A) \cdot P(A)}{P(B)}$$

Beweis

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} = \frac{\frac{P(A \cap B) \cdot P(A)}{P(A)}}{P(B)} = \frac{P(B \mid A) \cdot P(A)}{P(B)}$$

Bayes'sche Inferenz (Bayesian Inference)

Die Formel von Bayes beschreibt, wie wir eine Hypothese H nach Beobachtung von Daten D aktualisieren:

$$P(H \mid D) = \frac{P(D \mid H) \cdot P(H)}{P(D)}$$

Dabei heißen

$P(H)$	Prior,
$P(D \mid H)$	Likelihood,
$P(H \mid D)$	Posterior.

Diskrete Wahrscheinlichkeitsverteilung

Interpretation der Bayes'schen Inferenz

Wir starten mit einer anfänglichen Einschätzung $P(H)$ über eine Hypothese und passen diese durch neue Daten D an. Ist $P(D \mid H)$ groß, dann sprechen die Daten für die Hypothese; ist $P(D \mid H)$ klein, dann spricht das gegen sie.

Prior, Likelihood, Posterior

Prior $P(H)$:	unsere Einschätzung vor den Daten,
Likelihood $P(D \mid H)$:	wie gut erklärt H die Daten D,
Posterior $P(H \mid D)$:	unsere Einschätzung nach den Daten.

Wichtig: Die Likelihood ist nicht $P(H \mid D)$, sondern $P(D \mid H)$. Sie bewertet also die Daten unter der Annahme, dass die Hypothese gilt.

Typischer Ablauf

1. Formuliere mögliche Hypothesen $H_1, \ldots, H_k$.
2. Lege Prior-Wahrscheinlichkeiten $P(H_i)$ fest.
3. Modelliere die Datenwahrscheinlichkeit $P(D \mid H_i)$.
4. Berechne daraus die Posterior-Wahrscheinlichkeiten $P(H_i \mid D)$.
5. Entscheide z.B. mit der wahrscheinlichsten Hypothese (MAP-Regel).

Diskrete Wahrscheinlichkeitsverteilung

Beispiel: medizinischer Test

Sei $H =$ "Person ist krank" und $D =$ "Test ist positiv". Angenommen:

$$\begin{aligned} P(H) &= 0.01, \\ P(D \mid H) &= 0.99, \\ P(D \mid H^c) &= 0.05. \end{aligned}$$

Dann ist der Prior klein: Nur 1% der Personen sind krank. Die Likelihood $P(D \mid H) = 0.99$ sagt: Wenn jemand krank ist, ist der Test fast immer positiv.

Posterior berechnen

Mit Bayes folgt

$$\begin{aligned} P(H \mid D) &= \frac{P(D \mid H)P(H)}{P(D \mid H)P(H) + P(D \mid H^c)P(H^c)} \\ &= \frac{0.99 \cdot 0.01}{0.99 \cdot 0.01 + 0.05 \cdot 0.99} \approx 0.167. \end{aligned}$$

Obwohl der Test gut ist, liegt die Wahrscheinlichkeit nach einem positiven Test also nur bei etwa 16.7%.

Diskrete Wahrscheinlichkeitsverteilung

Bayes bei kontinuierlichen Verteilungen

Ist der unbekannte Parameter Θ selbst stetig verteilt, dann arbeiten wir mit Dichten statt mit einzelnen Wahrscheinlichkeiten. Für Prior-Dichte $p(\theta)$ und Likelihood-Dichte $f(x \mid \theta)$ gilt nach Beobachtung $X = x$:

$$p(\theta \mid x) = \frac{f(x \mid \theta)\, p(\theta)}{\int_{-\infty}^{\infty} f(x \mid u)\, p(u)\, du}.$$

Bei stetigen Verteilungen ist nämlich $P(X = x) = 0$; relevant ist daher die Dichte an der beobachteten Stelle x.

Diskrete Wahrscheinlichkeitsverteilung

Beispiel: Raumtemperatur und Thermometer

Sei Θ die wahre Raumtemperatur in Grad Celsius. Vor der Messung glauben wir, dass die Temperatur meistens in der Nähe von 20°C liegt:

$$\Theta \sim \mathcal{N}(20, 2^2).$$

Das Thermometer misst nicht perfekt, sondern mit einem Fehler von etwa 1°C. Also modellieren wir

$$X \mid \Theta = \theta \sim \mathcal{N}(\theta, 1^2).$$

Wenn das Thermometer nun $X = 24$ misst, dann ergibt sich als Posterior wieder eine Normalverteilung:

$$\Theta \mid X = 24 \sim \mathcal{N}(23.2, 0.8).$$

Interpretation

Der Prior sagt: Vor der Messung erwarten wir ungefähr 20°C. Die Likelihood sagt: Ein Messwert von 24°C ist besonders plausibel, wenn die wahre Temperatur in der Nähe von 24°C liegt. Der Posterior kombiniert beides: Nach der Messung halten wir Werte um 23.2°C für am plausibelsten.

Erinnerung Stochastische Unabhängigkeit

Zwei Ereignisse A, B heißen stochastisch unabhängig, falls

$$P(A \cap B) = P(A) \cdot P(B)$$

gilt. Gleichbedeutend damit ist $P(A|B) = P(A)$ und $P(B|A) = P(B)$.

Naiver Bayes'scher Spam Filter

Gegeben ist eine E-Mail E. Wir möchten anhand des Vorkommens bestimmter Wörter $A_1, \ldots A_n$ in der Mail entscheiden, ob es sich um eine erwünschte Mail H oder eine unerwünschte Mail S (Ham or Spam) handelt. (Typische Wörter wären zum Beispiel "reich", "casino", "Vergrösserung" ...)

Naiver Bayes'scher Spam Filter

Aus einer Datenbank kann man das Vorkommen dieser Wörter in Spam und Ham Mails zählen und damit empirisch die Wahrscheinlichkeiten $P(A_i|S)$ und $P(A_i|H)$ des Vorkommens dieser Wörter in Spam und Ham Mails ermitteln. Wir gehen davon aus, dass es sich bei der Mail prinzipiell mit Wahrscheinlichkeit $P(E = S) = P(E = H) = \frac{1}{2}$ um eine erwünschte Mail H oder eine unerwünschte Mail S handeln kann.

Naiver Bayes'scher Spam Filter

Wir machen zudem die (naive) Annahme, dass das Vorkommen der Wörter stochastisch unabhängig ist, also

$$P(A_1 \cap \cdots \cap A_n | S) = P(A_1|S) \cdot P(A_2|S) \cdots P(A_n|S)$$
$$P(A_1 \cap \cdots \cap A_n | H) = P(A_1|H) \cdot P(A_2|H) \cdots P(A_n|H)$$

gilt.

Naiver Bayes'scher Spam Filter

Mit der Formel von Bayes, der totalen Wahrscheinlichkeit und kürzen, da $P(S) = P(H)$ können wir somit berechnen

$$P(E = S|A_1 \cap \cdots \cap A_n) = \frac{P(A_1 \cap \cdots \cap A_n|S) \cdot P(S)}{P(A_1 \cap \cdots \cap A_n)}$$
$$= \frac{P(A_1|S) \cdots P(A_n|S)}{P(A_1 \cap \cdots \cap A_n|H) + P(A_1 \cap \cdots \cap A_n|S)}$$
$$= \frac{P(A_1|S) \cdots P(A_n|S)}{P(A_1|H) \cdots P(A_n|H) + P(A_1|S) \cdots P(A_n|S)}$$

Bemerkung: $P(E = H|A_1 \cap \cdots \cap A_n) = 1 - P(E = S|A_1 \cap \cdots \cap A_n)$

Diskrete Wahrscheinlichkeitsverteilung

Spamfilter als Bayes'sche Inferenz

Der naive Bayes-Filter ist ein klassisches Beispiel für Bayes'sche Inferenz:

$$\begin{aligned} &\text{Hypothesen: } H = \text{Ham}, \ S = \text{Spam}, \\ &\text{Daten: } D = A_1 \cap \cdots \cap A_n. \end{aligned}$$

Aus Prior und Likelihoods berechnen wir die Posterior-Wahrscheinlichkeiten

$$P(S \mid D), \qquad P(H \mid D).$$

Einordnung

- Prior: $P(S), P(H)$ beschreibt, wie wahrscheinlich Spam oder Ham vor den Wörtern ist.
- Likelihood: $P(D \mid S), P(D \mid H)$ misst, wie gut die beobachteten Wörter zu Spam oder Ham passen.
- Posterior: $P(S \mid D), P(H \mid D)$ kombiniert beides nach der Bayes-Formel.
- Entscheidung: Klassifiziere als Spam, falls $P(S \mid D) > P(H \mid D)$.

Erwartungswert

Eigenschaften

Sind $X, Y : \Omega \to \mathbb{R}^n$ reelle, integrierbare Zufallsvariablen und $a, b \in \mathbb{R}$ konstant, so gilt:

$$\mathbb{E}(a \cdot X + b \cdot Y) = a \cdot \mathbb{E}(X) + b \cdot \mathbb{E}(Y)$$

$$X(x) \leq Y(x) \; \forall x \in \Omega \Rightarrow \mathbb{E}(X) \leq \mathbb{E}(Y)$$

$$X, Y \text{ stoch. unabhängig} \Rightarrow \mathbb{E}(X \cdot Y) = \mathbb{E}(X) \cdot \mathbb{E}(Y)$$

$$\mathbb{E}(1_A) = P(A)$$

Varianz

Für eine reelle Zufallsvariable ist die Varianz definiert durch

$$\mathbb{V}(X) := \mathbb{E}((X - \mathbb{E}(X))^2) \, .$$

Verschiebungssatz

$$\begin{aligned}\mathbb{V}(X) &= \mathbb{E}(X^2 - 2X\mathbb{E}(X) + \mathbb{E}(X)^2) = \mathbb{E}(X^2) - 2\mathbb{E}(X)^2 + \mathbb{E}(X)^2 \\ &= \mathbb{E}(X^2) - \mathbb{E}(X)^2\end{aligned}$$

Kovarianz

Für reelle Zufallsvariable X, Y ist die Kovarianz definiert durch

$$\mathcal{C}(X, Y) := \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y))) \,.$$

Kovarianz

Per Definition ist

$$\mathcal{C}(X, X) := \mathbb{V}(X).$$

Erwartungswert

Beispiel

$\Omega = \{\text{Kopf}, \text{Zahl}\}$, $P(\text{Kopf}) = P(\text{Zahl}) = \frac{1}{2}$,
$X(\text{Kopf}) = 0, X(\text{Zahl}) = 1$

$$\begin{aligned}\mathbb{E}(X) &= 0 \cdot P(X^{-1}(0)) + 1 \cdot P(X^{-1}(1)) \\ &= 0 \cdot P(\text{Kopf}) + 1 \cdot P(\text{Zahl}) = \frac{1}{2}\end{aligned}$$

Erwartungswert

Beispiel

Sei $X \sim \mathcal{N}(\mu, \sigma^2)$.

$$\begin{aligned}
\mathbb{E}(X) &:= \int_{\mathbb{R}} x \cdot \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}(\frac{x-\mu}{\sigma})^2}\, dx \\
&= \int_{\mathbb{R}} (y+\mu) \cdot \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}y^2}\, dy \\
&= \mu \int_{\mathbb{R}} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}y^2}\, dy + \int_{\mathbb{R}} y \cdot \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}y^2}\, dy = \mu
\end{aligned}$$

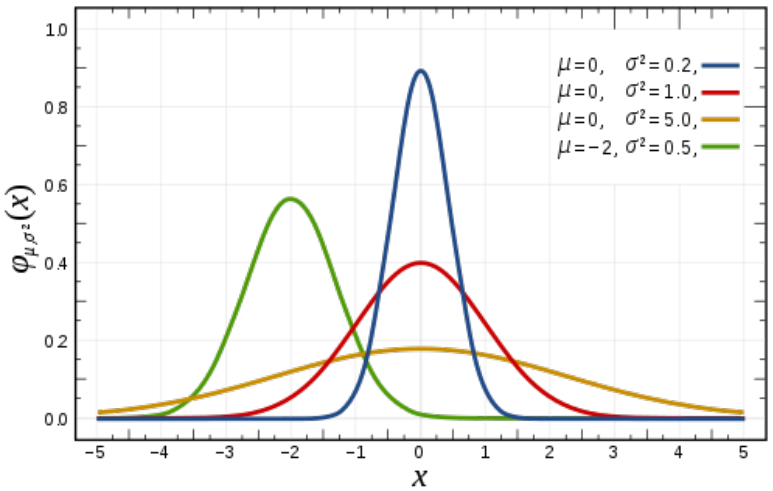

Figure: Quelle: Wikipedia

Beispiel

Sei $X \sim \mathcal{N}(\mu, \sigma^2)$.

$$\mathbb{V}(X) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} x^2 e^{-\frac{x^2}{2}}\, dx = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} x(xe^{-\frac{x^2}{2}})\, dx$$
$$= \frac{1}{\sqrt{2\pi}} \left(\left[x(e^{-\frac{x^2}{2}}) \right]_{-\infty}^{\infty} - \int_{-\infty}^{\infty} -e^{-\frac{x^2}{2}}\, dx \right) = 0 + 1 = 1$$

LINK: Partielle Integration. Mit "Verschiebungstrick"
$\Rightarrow \mathbb{V}(X) = \sigma^2$.

Markov Ungleichung

Sei $Y : \Omega \to \mathbb{R}$ eine reelle, integrierbare Zufallsvariable und $f : [0, \infty) \to [0, \infty)$ monoton wachsend. Dann gilt für alle $\epsilon > 0$ mit $f(\epsilon) > 0$

$$P(|Y| \geq \epsilon) \leq \frac{\mathbb{E}(f \circ |Y|)}{f(\epsilon)}$$

Beweis

Da $f(\epsilon)1_{\{|Y| \geq \epsilon\}} \leq f \circ |Y|$ folgt

$$\begin{aligned} f(\epsilon)P(|Y| \geq \epsilon) =& f(\epsilon)\mathbb{E}(1_{\{|Y| \geq \epsilon\}}) = \mathbb{E}(f(\epsilon)1_{\{|Y| \geq \epsilon\}}) \\ \leq& \mathbb{E}(f \circ |Y|) \end{aligned}$$

Tschebyscheff-Ungleichung

Für eine reelle, integrierbare und quadratintegrierbare Zufallsvariable $Y : \Omega \to \mathbb{R}$ gilt:

$$P(|Y - \mathbb{E}(Y)| \geq \epsilon) \leq \frac{\mathbb{V}(Y)}{\epsilon^2}$$

Beweis

Folgt direkt aus der Markov-Ungleichung mit $Y' = Y - \mathbb{E}(Y)$ und $f(x) = x^2$

Schwaches Gesetz der großen Zahlen

Seien $X_i : \Omega \to \mathbb{R}$ unabhängige, reelle Zufallsvariablen (uiv, iid(englisch)) mit $\mathbb{E}(X_i) = \mu < \infty$ und $\mathbb{V}(X_i) = \sigma < \infty$, dann gilt

$$P\left(\left|\frac{1}{n}\sum_{i=1}^{n} X_i - \mu\right| \geq \epsilon\right) \leq \frac{\sigma}{n \cdot \epsilon^2} \quad \underset{n\to\infty}{\longrightarrow} 0$$

(stochastische Konvergenz).

Beweis

Mit $Y_n = \frac{1}{n}\sum_{i=1}^{n} X_i - \mu$ ist $\mathbb{E}(Y_n) = \frac{1}{n}\sum_{i=1}^{n} \mathbb{E}(X_i - \mu) = 0$ und $\mathbb{V}(Y_n) = \frac{1}{n^2}\sum_{i=1}^{n} \mathbb{V}(X_i) = \frac{\sigma}{n}$. Aus der Tschebyscheff-Ungleichung folgt die Behauptung.
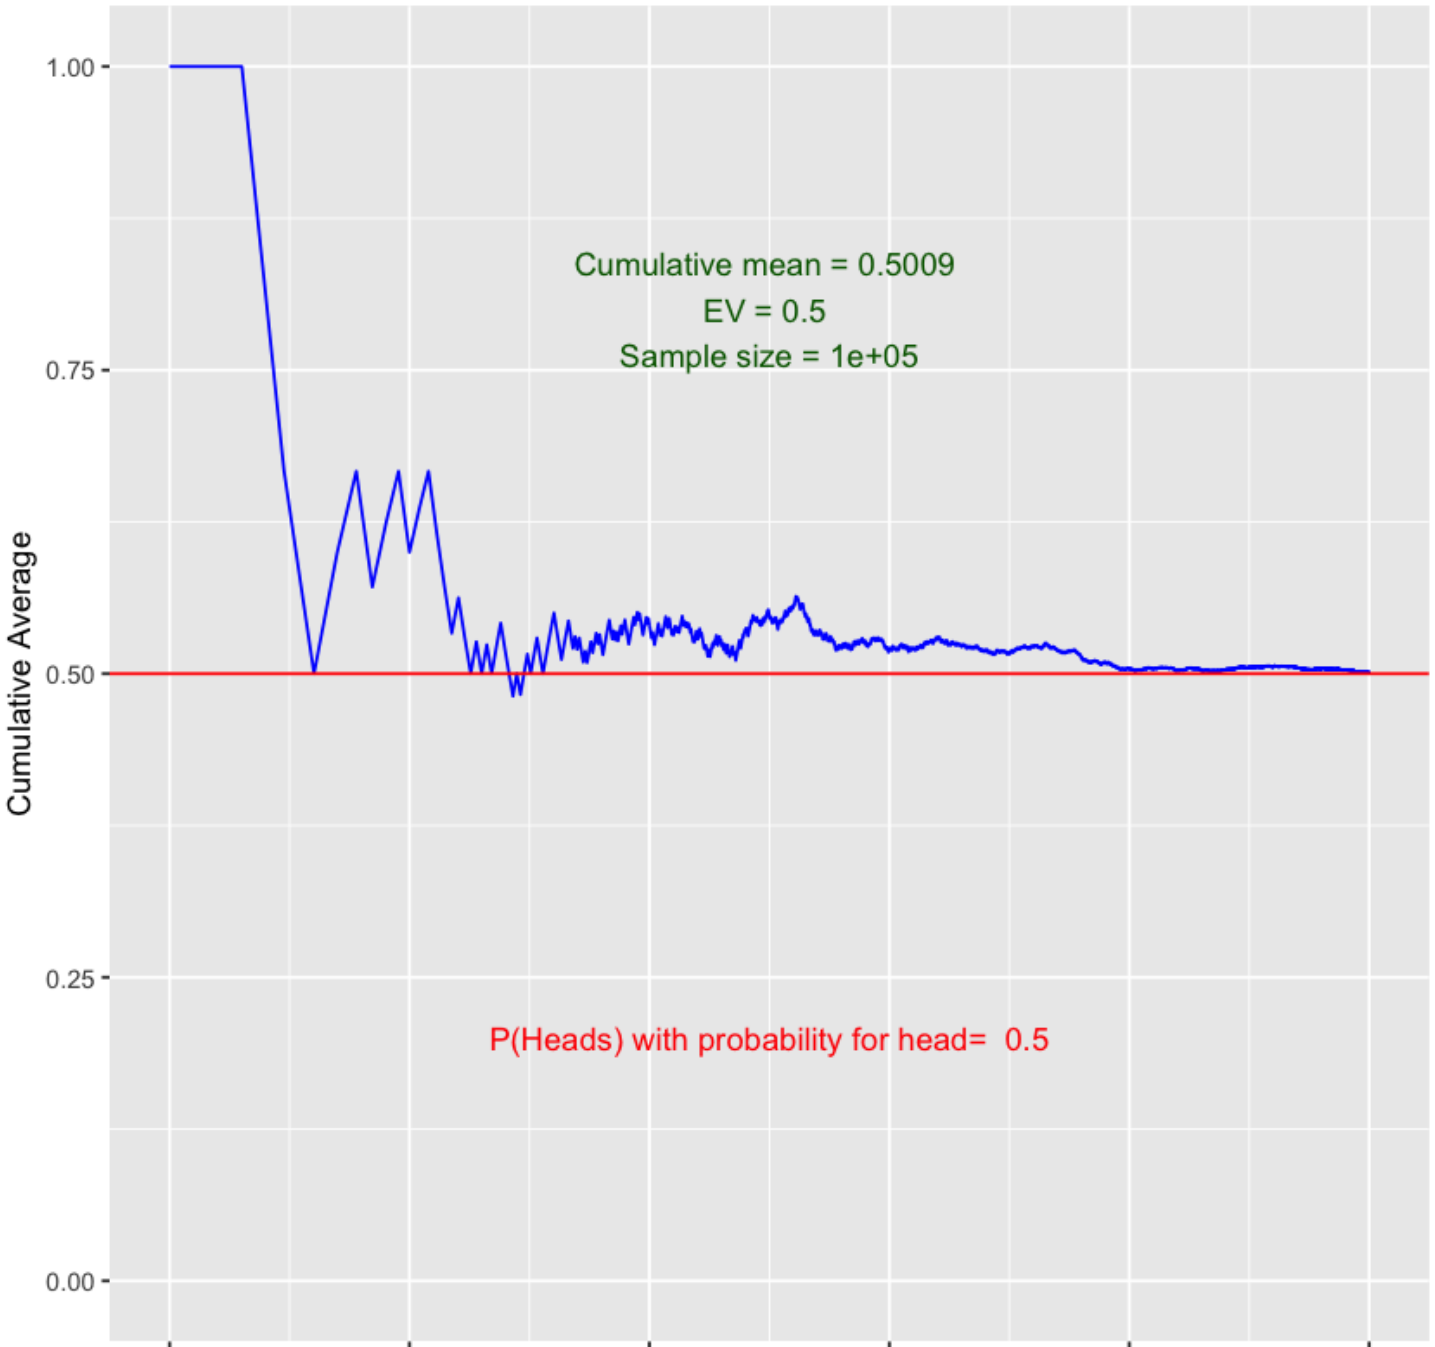
Erwartungswert